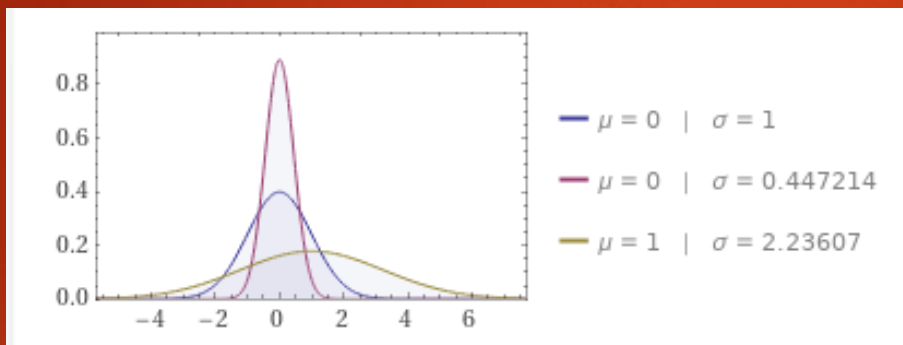


Přednáška 4.

- ▶ Věrohodnostní funkce
- ▶ Rao-Cramérova dolní mez (Cramér-Rao Lower Bound)

Věrohodnost: Rozptyl odhadu



PDF jako funkci neznámého parametru nazýváme **věrohodnostní funkce** (likelihood function):

$$p(\theta|x) = \prod_{i=1}^N p(\theta|x_i)$$

- Čím větší „sharpness“ křivky, tím lépe půjde odhadnout.

- Často se využívá místo věrohodnostní funkce její logaritmus, tzv. **log-likelihood function** (označme symbolem \mathcal{L}).
- Derivace $\mathcal{L} \rightarrow$ používá se pro nalezení maxima. Pro uvažované hustoty pravděpodobnosti předpokládáme, že splňují podmínku „regularity“, tedy

$$E \left[\frac{\partial \ln p(\theta|x)}{\partial \theta} \right] = 0, \text{ for all } \theta$$

- Druhá derivace $\mathcal{L} \rightarrow$ používá se pro popis tvaru křivky (konvexní / konkávní)
Jaký průběh má pdf? Jaké znaménko má její derivace?

Skalární Rao-Cramérova dolní mez

Předpokládejme, že hustota pravděpodobnosti $p(\theta|x)$ splňuje podmínku regularity. Potom rozptyl libovolného nestranného odhadu splňuje

$$\text{var}(\hat{\theta}) \geq \frac{1}{-E\left[\frac{\partial^2 \ln p(\theta|x)}{\partial \theta^2}\right]}, \text{ kde derivaci vyčíslíme ve skutečné hodnotě parametru } \theta.$$

- Tuto mez nazýváme Rao-Cramérova dolní mez (Cramér-Rao Lower Bound = CRLB).
- Výraz $\mathcal{I}(\theta) = -E\left[\frac{\partial^2 \ln p(\theta|x)}{\partial \theta^2}\right]$ nazýváme Fisherova informace (FI).
- Nestranný odhad, který dosahuje CRLB je **nejlepší nestranný odhad** (někdy také *eficientní*).
- Pro FI platí: $\mathcal{I}(\theta) = -E\left[\frac{\partial^2 \ln p(\theta|x)}{\partial \theta^2}\right] = E\left[\left(\frac{\partial}{\partial \theta} \ln p(\theta|x)\right)^2\right]$

Skalární Rao-Cramérova dolní mez

Další vlastnosti CRLB

- Pokud lze vyjádřit $\frac{\partial}{\partial \theta} \ln p(\theta|x) = I(\theta)(g(x) - \theta)$, kde $I(\theta)$ a $g(x)$ jsou libovolné funkce (ovšem závislé jenom na argumentu, který je zapsaný, popř. na hyperparametrech), pak $\hat{\theta} = g(x)$ je nestranný odhad dosahující CRLB.
- Máme-li i.i.d. model dat a tedy $p(\theta|x) = \prod_{i=1}^N p(\theta|x_i)$, pak Fisherova informace celého pozorování $x_1 \dots x_N$ je rovna N -násobku Fisherovy informace jednoho (kteréhokoliv) pozorování. CRLB má potom nutně tvar násobku $\frac{1}{N}$.

Cvičení 4

1. Ukažte vztah $\mathcal{I}(\theta) = -E \left[\frac{\partial^2 \ln p(\theta|x)}{\partial \theta^2} \right] = E \left[\left(\frac{\partial}{\partial \theta} \ln p(\theta|x) \right)^2 \right]$.
2. Chceme odhadnout úroveň stejnosměrného proudu z nepřesných měření X_1, X_2, \dots, X_n , tzn. při modelu $X_i = A + w_i$, $w_i \sim N(0,1)$. Spočítejte CRLB odhadu parametru A . Který z odhadů je lepší?
 - ▶ $\hat{A} = \frac{1}{n} \sum_{i=1}^n X_i$ a nebo
 - ▶ $\hat{A} = \frac{1}{n+2} (2X_1 + \sum_{i=2}^{n-1} X_i + 2X_n)$?
3. Stejný příklad jako 2 pokud $w_i \sim N(0, \sigma^2)$, σ^2 známe.
4. $X_i = Ar^i + w_i$, kde $r > 0$ (známé) a $w_i \sim N(0, \sigma^2)$, σ^2 známe. Spočtete CRLB a analyzujte pro různé hodnoty r .