

Přednáška 5.

- ▶ Vektorová náhodná veličina
- ▶ Vícerozměrné Normální rozdělení
- ▶ Kovariance, kovarianční matice
- ▶ Věta o transformaci
- ▶ Odhady vektorových parametrů
- ▶ CRLB

Vektorová náhodná veličina

Vektorová náhodná veličina $\mathbf{X} = (X_1, \dots, X_n)^T$

Sdružená distribuční funkce

$$F_{\mathbf{X}}(\mathbf{x}) = F_{X_1, \dots, X_n}(x_1, \dots, x_n) = P([X_1 \leq x_1] \cap \dots \cap [X_n \leq x_n])$$

Sdružená hustota pravděpodobnosti

$$f_{\mathbf{X}}(\mathbf{x}) = f_{X_1, \dots, X_n}(x_1, \dots, x_n)$$

Vztah mezi distribuční funkcí a hustotou

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1, \dots, dx_n$$

Vícerozměrné normální rozdělení

Sdružená hustota pravděpodobnosti náhodné vektorové veličiny $\mathbf{X} = (X_1, X_2, \dots, X_N)^T$ mající Normální rozdělení

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{N}{2}} (\det(\Sigma))^{\frac{1}{2}}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x}-\boldsymbol{\mu})}$$

Kde $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_N)^T = E[(X_1, X_2, \dots, X_N)^T]$ a $\Sigma = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T]$

Pro vektor dimenze 2 je pak hustota

$$f_{X,Y}(x,y) = \frac{1}{2\pi} \frac{1}{\sqrt{\det \Sigma}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x}-\boldsymbol{\mu})}$$

$$\text{Kde } \Sigma = \begin{pmatrix} E[(X - \mu_x)^2] & E[(X - \mu_x)(Y - \mu_y)] \\ E[(X - \mu_x)(Y - \mu_y)] & E[(Y - \mu_y)^2] \end{pmatrix} = \begin{pmatrix} \sigma_x^2 & \rho\sigma_x\sigma_y \\ \rho\sigma_x\sigma_y & \sigma_y^2 \end{pmatrix}$$

Kovariance, kovarianční matice

Vektor střední hodnoty

$$\boldsymbol{\mu} = E[\mathbf{X}]$$

Kovarianční maticí nazýváme matici

$$\text{cov}(\mathbf{X}) = \boldsymbol{\Sigma} = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = E[\mathbf{X}\mathbf{X}^T] - \boldsymbol{\mu}\boldsymbol{\mu}^T$$

Pozn.: kovarianční matice je zobecněním rozptylu pro vektorové náhodné veličiny

Kovariance mezi náhodnými veličinami X a Y

$$\text{cov}(X, Y) = E[(X - \mu_x)(Y - \mu_y)]$$

Transformace hustoty

Uvažujme náhodnou vektorovou veličinu $\mathbf{X} = (X_1, \dots, X_N)^T$, a z ní vytvořme náhodnou veličinu $\mathbf{Y} = (Y_1, \dots, Y_N)^T$ jako $\mathbf{Y} = h(\mathbf{X})$.

Nechť $\mathbf{X} = (X_1, \dots, X_N)$ je spojitá náhodná veličina, $h : R^N \rightarrow R^N$ ryze monotónní funkce na množině $\mathbf{X}(\Omega)$ a h^{-1} je diferencovatelná a splňuje podmínku

$$J = \begin{bmatrix} \frac{\partial h_1^{-1}}{\partial y_1} & \dots & \frac{\partial h_1^{-1}}{\partial y_N} \\ \vdots & \ddots & \vdots \\ \frac{\partial h_N^{-1}}{\partial y_1} & \dots & \frac{\partial h_N^{-1}}{\partial y_N} \end{bmatrix} \neq 0$$

Potom náhodná veličina $\mathbf{Y} = h(\mathbf{X})$ má hustotu pravděpodobnosti

$$f_Y(\mathbf{y}) = f_X\left(h_1^{-1}(\mathbf{y}), \dots, h_N^{-1}(\mathbf{y})\right) |J|$$

Příklad: $X, Y \sim N(0,1)$ a jsou nezávislé. Jaká je hustota pravděpodobnosti vektoru $(X - Y, X + Y)$?

Příklad: $\mathbf{X} = (X_1, \dots, X_N)^T$ je vektorová náhodná veličina a $\mathbf{Y} = \mathbf{A}\mathbf{X}$, kde \mathbf{A} je regulární matice. Jaká je hustota pravděpodobnosti \mathbf{Y} ?

Odhad (vektorových) parametrů

Odhadovaný parametr $\theta = \begin{pmatrix} \theta_1 \\ \vdots \\ \theta_d \end{pmatrix}$

Např. $\theta = \begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix}$, tedy parametry Normálního rozdělení, nebo odhad kovarianční matice, lineární regrese

Už jsme viděli, že nestranný odhad σ^2 se liší v případech, kdy (ne)známe skutečnou hodnotu parametru μ .

a) Známe μ :

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$$

b) Neznáme μ a nahradíme ho výběrovým průměrem:

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Rao-Cramérova dolní mez

- Fisherova informace je pro případ odhadu vektoru parametrů reprezentovaná **Fisherovou Informační Maticí (FIM) $F(\theta)$** .
- Pro $F(\theta)$ platí

$$F(\theta)_{i,j} = E \left[\left(\frac{\partial \ln f(\theta|x)}{\partial \theta_i} \right) \left(\frac{\partial \ln f(\theta|x)}{\partial \theta_j} \right) \right] = -E \left[\frac{\partial^2}{\partial \theta_i \partial \theta_j} \ln f(\theta|x) \right]$$

- Nechť $\hat{\theta}$ je nestranný odhad parametru θ tj. $E[\hat{\theta}] = \theta$. Platí, že

$$\text{cov}(\hat{\theta}) \geq F^{-1}(\theta),$$

což znamená, že matice $\text{cov}(\hat{\theta}) - F^{-1}(\theta)$ je pozitivně semidefinitní.

Příklad: Nechť a je vektor stejných rozměrů jako θ . Uvažujme skalární odhad $\hat{a} = a^T \hat{\theta}$, což je nestranný odhad $a^T \theta$. Pak platí

$$\text{var}(\hat{a}) = \text{cov}(a^T \hat{\theta}) = a^T \text{cov}(\hat{\theta}) a \geq a^T F^{-1}(\theta) a.$$

Když například $a = (1, 0, \dots)^T$, pak $\hat{a} = a^T \hat{\theta} = \hat{\theta}_1$, a CRLB říká, že $\text{var}(\hat{\theta}_1) \geq F^{-1}(\theta)_{11}$.

Rao-Cramérova dolní mez pro gaussovská pozorování

- Necht' $\mathbf{x} \sim N(\boldsymbol{\mu}(\boldsymbol{\theta}), \mathbf{C}(\boldsymbol{\theta}))$, kde $\boldsymbol{\theta}$ jsou parametry modelu a tedy $\boldsymbol{\mu}(\boldsymbol{\theta})$ a $\mathbf{C}(\boldsymbol{\theta})$ popisují (obecně nelineární) závislost střední hodnoty a kovarianční matice pozorování na těchto parametrech.
- Pro FIM $\mathbf{F}(\boldsymbol{\theta})$ platí

$$\mathbf{F}(\boldsymbol{\theta})_{i,j} = \left[\frac{\partial \boldsymbol{\mu}(\boldsymbol{\theta})}{\partial \theta_i} \right]^T \mathbf{C}^{-1}(\boldsymbol{\theta}) \frac{\partial \boldsymbol{\mu}(\boldsymbol{\theta})}{\partial \theta_j} + \frac{1}{2} \text{tr} \left[\mathbf{C}^{-1}(\boldsymbol{\theta}) \frac{\partial \mathbf{C}(\boldsymbol{\theta})}{\partial \theta_i} \mathbf{C}^{-1}(\boldsymbol{\theta}) \frac{\partial \mathbf{C}(\boldsymbol{\theta})}{\partial \theta_j} \right]$$

Cvičení 5

1. Spočítejte Rao-Cramérovu dolní mez pro odhad rozptylu Normálního rozdělení, jestliže střední hodnotu známe.
2. Generujte i.i.d. veličiny z Normálního rozdělení s nulovou střední hodnotou a rozptylem σ^2 . Odhadněte rozptyl σ^2 . Proveďte MC simulaci, abyste odhadli rozptyl odhadu σ^2 a porovnejte s příslušnou CRLB.
3. Řešte úlohy 3.4, 3.9 a 3.11 v knize SMK