

# Přednáška 7.

- ▶ Metoda maximální věrohodnosti (MLE)

# Metoda maximální věrohodnosti

## Připomenutí:

PDF jako funkci neznámého parametru nazýváme **věrohodnostní funkce** (likelihood function):

$$p(\theta|\mathbf{x}) = \prod_{i=1}^N p(\theta|x_i)$$

## Princip maximálně věrohodného odhadu (Maximum Likelihood Estimation – MLE):

Maximalizovat věrohodnost = odhadnout neznámý parametr tak, aby „co nejlépe“ odpovídal modelu dat

1. Často se opět využívá místo věrohodnostní funkce její logaritmus, tzv. **log-likelihood function** (označme symbolem  $\mathcal{L}$ ).
2. Derivace  $\mathcal{L} \rightarrow$  používá se pro nalezení maxima, tedy

$$\frac{\partial \ln p(\theta|\mathbf{x})}{\partial \theta} = 0$$

# MLE - vlastnosti

**Asymptotické rozdělení MLE odhadu:**

$$\hat{\theta}_{MLE} \sim N(\theta, \mathcal{I}^{-1}(\theta))$$

Kde  $\mathcal{I}^{-1}(\theta)$  je inverze Fisherovy informační matice.

**Důsledky:**

1. MLE odhady jsou asymptoticky nestranné.
2. MLE odhady jsou asymptoticky eficientní! Dosahují CRLB.
3. Přesnost MLE odhadů se dá (někdy) analyticky odvodit.

Příklad 1: Jak vypadá MLE odhad střední hodnoty exponenciálního rozdělení?

Příklad 2: Jak vypadá MLE odhad parametru  $\mu$  pro rozdělení, které má hustotu pravděpodobnosti

$$f_X(x) = \frac{\beta}{2\alpha\Gamma(1/\beta)} e^{-\left(\frac{|x-\mu|}{\alpha}\right)^\beta}. \text{ Pro jednoduchost zkusme uvažovat např. } \alpha = 1.$$

# MLE – numerické řešení

Nelze nalézt analyticky taková  $\theta$ , že platí  $\frac{\partial \ln p(\theta|x)}{\partial \theta} = 0$ . Proto označme

$$g(\theta) = \frac{\partial \ln p(\theta|x)}{\partial \theta}$$

A využijme rozvoj funkce  $g(\theta)$  v okolí bodu  $\theta_0$

$$g(\theta) \approx g(\theta_0) + \frac{\partial g(\theta)}{\partial \theta} \Big|_{\theta=\theta_0} (\theta - \theta_0)$$

A z toho odvodíme vztah

$$\theta_1 = \theta_0 - \frac{g(\theta_0)}{\frac{\partial g(\theta)}{\partial \theta} \Big|_{\theta=\theta_0}}$$

A následně rekurentní vztah

$$\theta_{k+1} = \theta_k - \frac{g(\theta_k)}{\frac{\partial g(\theta)}{\partial \theta} \Big|_{\theta=\theta_k}}$$

Tato iterativní procedura se nazývá Newton-Raphsonův algoritmus.

Poznámky:

- Hrozí problémy s konvergencí (obzvláště pokud druhá derivace log-likelihood je malá)
- Velmi závisí na inicializaci (při špatné inicializaci hrozí konvergence k lokálním maximům, ale dokonce i minimům).

# Cvičení 7

1. Spočtěte MLE odhad střední hodnoty Normálního rozdělení.
2. Odhadněte parametr  $\mu$  z dat, která mají rozdělení s hustotu pravděpodobnosti

$$f_X(x) = \frac{\beta}{2\alpha\Gamma(1/\beta)} e^{-\left(\frac{|x-\mu|}{\alpha}\right)^\beta}, \text{ kde } \alpha = 1 \text{ a } \beta = 4.$$