

přednáška 11

- ▶ Volba apriorní hustoty pravděpodobnosti
- ▶ MMSE vs. MAP
- ▶ Wienerův filtr

Volba apriorní hustoty

Připomenutí: aposteriorní hustota pravděpodobnosti má tvar

$$p(A|x) = \frac{p(x|A)p(A)}{p(x)} = \frac{p(x|A)p(A)}{\int p(x|A)p(A)dA}$$

Kde hustota $p(A)$ je apriorní hustota pravděpodobnosti.

Nejběžnější volby pro $p(A)$ jsou uniformní a normální pdf.

1. Pokud $p(x|A)$ modelujeme jako hustotu normálního rozdělení, pak díky volbě $A \sim U(a, b)$ nebo $A \sim N(\mu_A, \sigma_A^2)$ bude i aposteriorní hustota $p(A|x)$ normální.
2. Tomuto odpovídá např. model dat $x = A + w$, kde $w \sim N(\mu, \sigma^2)$. Pro odhady \hat{A} se dá ukázat, že

$$a) \hat{A} = \frac{\frac{N}{\sigma^2} \bar{x} + \frac{\mu_A}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}, \text{ pokud } A \sim N(\mu_A, \sigma_A^2).$$

$$b) \text{ Aposteriorní rozptyl je dán jako } var(A|x) = \sigma_{A|x}^2 = \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}.$$

$$c) BMSE(\hat{A}) < \frac{\sigma^2}{N}$$

Metody bayesovských odhadů

Minimum Mean Square Error

$$Bmse(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \int \left[\int (\hat{\theta} - \theta)^2 p(\theta|x) d\theta \right] p(x) dx$$

$$\hat{\theta} = E[\theta|x] = \int \theta p(\theta|x) d\theta$$

Maximum A posteriori Estimators

$$\hat{\theta} = \arg \max_{\theta} p(\theta|x)$$

$$p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$$

$$\hat{\theta} = \arg \max_{\theta} p(x|\theta)p(\theta)$$

Příklad: Odhad parametru θ exponenciálního rozdělení, pokud předpokládáme apriorní hustotu jako $p(\theta) = \lambda e^{-\lambda\theta}$, pro $\theta > 0$ a $p(\theta) = 0$ jinak.

Lineární bayesovský odhad

Linear minimum MSE (LMMSE):

$$\hat{\theta} = \sum_{k=1}^N a_k x_k + a_0$$

- Založeno na korelaci mezi odhadovaným parametrem θ a daty x_k , $k=1, \dots, N$. Parametr nekorelovaný s daty nemůže být takto odhadován.
- Není potřeba znát pdf $p(x, \theta)$.
- a_0 je potřeba pouze pokud x, θ mají nenulové střední hodnoty.
- Pouze suboptimální v případě nelineárních modelů.
- Koeficienty a_k nalezneme minimalizací $Bmse(\hat{\theta}) = E[(\theta - \hat{\theta})^2]$.

Příklad:

Odhadujeme θ pouze z jediného pozorování $x_1 \sim N(0, \sigma^2)$, skutečná hodnota je $\theta = x_1^2$, tudíž nejlepší odhad by byl $\hat{\theta} = x_1^2$.

LMMSE bude $\hat{\theta} = a_0 + a_1 x_1$, ale ...

Lineární bayesovský odhad

Optimální volba koeficientů dává LMMSE ve tvaru:

$$\hat{\theta} = E[\theta] + \mathbf{C}_{\theta x} \mathbf{C}_{xx}^{-1} (x - E[x])$$

- \mathbf{C}_{xx} je $N \times N$ kovarianční matice náhodné veličiny x
- $\mathbf{C}_{\theta x} = \mathbf{C}_{x\theta}^T$ je $1 \times N$ kovariance mezi θ a x

Vektorová verze:

- Koeficienty hledáme tak, aby minimalizovali $B_{mse}(\hat{\theta}_i) = E[(\theta_i - \hat{\theta}_i)^2]$ pro všechny prvky vektorového parametru θ ($i = 1, \dots, d$).
- LMMSE je tedy tvaru:

$$\hat{\boldsymbol{\theta}} = E[\boldsymbol{\theta}] + \mathbf{C}_{\boldsymbol{\theta} x} \mathbf{C}_{xx}^{-1} (x - E[x])$$

- Kde \mathbf{C}_{xx} je $N \times N$ kovarianční matice náhodné veličiny x
- $\mathbf{C}_{\boldsymbol{\theta} x} = \mathbf{C}_{x\boldsymbol{\theta}}^T$ je $d \times N$ kovariance mezi $\boldsymbol{\theta}$ a x

Signal processing – Wiener filter

Uvažujme $\mathbf{x} = [x[1], x[2], \dots, x[N]]$ náhodný vektor s nulovou střední hodnotou a kovariancí

$$\mathbf{C}_{xx} = \begin{bmatrix} r_{xx}[1] & \cdots & r_{xx}[N] \\ \vdots & \ddots & \vdots \\ r_{xx}[N] & \cdots & r_{xx}[1] \end{bmatrix}$$

Tedy r_k je ACF (autocorrelation function) procesu $x[N + 1]$ a \mathbf{C}_{xx} je jeho autokorelační matice.

Wienerovými filtry nazveme 3 základní aplikace toho problému:

1. Filtrování = odhadujeme signál $\theta = s[N]$ v modelu $x[k] = s[k] + w[k]$, $k = 1, \dots, N$ (pro odhad používáme pouze data přítomná a minulá (pro odhad $s[2]$ mohu využít jen $x[1], x[2]$)
2. Vyhlazování (smoothing) = stejné jako filtrování, ale nad celými daty.
3. Predikce = odhadujeme $\theta = s[N + k]$ na základě $x[1], x[2], \dots, x[N]$

Ve všech případech uvažujeme $E[\boldsymbol{\theta}] = E[\mathbf{x}] = 0$, tedy

$$\hat{\boldsymbol{\theta}} = \mathbf{C}_{\theta x} \mathbf{C}_{xx}^{-1} \mathbf{x}$$

cvičení 11

- ▶ Házejte mincí a odhadujte z dat pravděpodobnost, že padne orel.
- ▶ Majitel e-shopu má data o denních prodejích za prvních 290 dní v roce. Přijde mu, že za posledních 16 dní jdou prodeje nahoru a chtěl by na základě této hypotézy odhadnout, kolik bude mít prodejů do konce roku.