

přednáška 11

- ▶ Opakování
- ▶ Lineární bayesovský MMSE odhad (LMMSE)
- ▶ Wienerův filtr

Volba apriorní hustoty

Připomenutí: aposteriorní hustota pravděpodobnosti má tvar

$$p(A|x) = \frac{p(x|A)p(A)}{p(x)} = \frac{p(x|A)p(A)}{\int p(x|A)p(A)dA}$$

Kde hustota $p(A)$ je apriorní hustota pravděpodobnosti.

Nejběžnější volby pro $p(A)$ jsou uniformní a normální pdf.

1. Pokud $p(x|A)$ modelujeme jako hustotu normálního rozdělení, pak díky volbě $A \sim U(a, b)$ nebo $A \sim N(\mu_A, \sigma_A^2)$ bude i aposteriorní hustota $p(A|x)$ normální.
2. Tomuto odpovídá např. model dat $x = A + w$, kde $w \sim N(\mu, \sigma^2)$. Pro odhady \hat{A} se dá ukázat, že

$$a) \hat{A} = \frac{\frac{N}{\sigma^2} \bar{x} + \frac{\mu_A}{\sigma_A^2}}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}, \text{ pokud } A \sim N(\mu_A, \sigma_A^2).$$

$$b) \text{Aposteriorní rozptyl je dán jako } var(A|x) = \sigma_{A|x}^2 = \frac{1}{\frac{N}{\sigma^2} + \frac{1}{\sigma_A^2}}.$$

$$c) \text{BMSE}(\hat{A}) < \frac{\sigma^2}{N}$$

Metody bayesovských odhadů

Minimum Mean Square Error (MMSE)

$$Bmse(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = \int \left[\int (\hat{\theta} - \theta)^2 p(\theta|x) d\theta \right] p(x) dx$$
$$\hat{\theta} = E[\theta|x] = \int \theta p(\theta|x) d\theta$$

Maximum A posteriori Estimators

$$\hat{\theta} = \arg \max_{\theta} p(\theta|x)$$
$$p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$$
$$\hat{\theta} = \arg \max_{\theta} p(x|\theta)p(\theta)$$

Často je obtížné odvodit tyto odhady analyticky. MMSE vyžaduje odvození celé aposteriorní hustoty, což obnáší integraci $p(x|\theta)p(\theta)$. MAP vyžaduje hledání globálního maxima mnohorozměrné funkce.

Lineární bayesovský odhad

Zjednodušení: Uvažujeme lineární (skalární) bayesovský MMSE odhad (LMMSE):

$$\hat{\theta} = \sum_{k=1}^N a_k x_k + a_0$$

- θ je náhodný parametr, \mathbf{x} a θ mají sdružené pdf $p(\mathbf{x}, \theta)$, nebude ho ale potřeba znát.
- Ukáže se, že je třeba předpokládat korelaci mezi θ a \mathbf{x} . Parametr nekorelovaný s daty nemůže být takto odhadován.
- a_0 je potřeba pouze pokud \mathbf{x} a θ mají nenulové střední hodnoty.
- Odhad bude suboptimální v případě negaussovských modelů.
- Koeficienty a_k nalezneme minimalizací $B_{\text{mse}}(\hat{\theta}) = E[(\theta - \hat{\theta})^2]$.

Příklad (co se stane, když parametr není korelovaný s daty):

Odhadujeme θ pouze z jediného pozorování $x_1 \sim N(0, \sigma^2)$, kdy $\theta = x_1^2$, tudíž nejlepší odhad by byl $\hat{\theta} = x_1^2$. LMMSE je $\hat{\theta} = a_0 + a_1 x_1$. Dořešte příklad.

Lineární bayesovský odhad

Optimální volba koeficientů dává LMMSE ve tvaru:

$$\hat{\theta} = E[\theta] + \mathbf{C}_{\theta x} \mathbf{C}_{xx}^{-1} (x - E[x])$$

- \mathbf{C}_{xx} je $N \times N$ kovarianční matice x
- $\mathbf{C}_{\theta x} = \mathbf{C}_{x\theta}^T$ je $1 \times N$ kovariance mezi θ a x

Vektorový parametr θ :

- Koeficienty hledáme tak, aby minimalizovali $\text{Bmse}(\hat{\theta}_i) = E[(\theta_i - \hat{\theta}_i)^2]$ pro všechny prvky vektorového parametru θ ($i = 1, \dots, d$).
- LMMSE je tedy tvaru:

$$\hat{\theta} = E[\theta] + \mathbf{C}_{\theta x} \mathbf{C}_{xx}^{-1} (x - E[x])$$

- Kde \mathbf{C}_{xx} je $N \times N$ kovarianční matice náhodné veličiny x
- $\mathbf{C}_{\theta x} = \mathbf{C}_{x\theta}^T$ je $d \times N$ kovariance mezi θ a x

Vidíme, že pro výpočet odhadu nám stačí střední hodnoty a kovariance θ a x , pdf může být libovolné.

Wienerovy filtry ve zpracování signálů

Lineární bayesovské odhady jsou obecně nazývány **Wienerovy filtry**.

Uvažujme $\mathbf{x} = [x[1], x[2], \dots, x[N]]$ náhodný vektor s nulovou střední hodnotou a kovariancí \mathbf{C}_{xx} . Pokud je \mathbf{x} tzv. slabě stacionární proces – WSS (zjednodušeně: střední hodnota a kovariance jsou nezávislé na čase), pak

$$\mathbf{C}_{xx} = \begin{bmatrix} r_{xx}[1] & \cdots & r_{xx}[N] \\ \vdots & \ddots & \vdots \\ r_{xx}[N] & \cdots & r_{xx}[1] \end{bmatrix}$$

kde $r_{xx}[t] = E[x[n]x[n+t]]$ je autokorelační funkce (\mathbf{x} je WSS takže $r_{xx}[t]$ nezávisí na n).

Tři základní aplikace LMMSE ve zpracování signálů (Wienerův filtr):

1. **Odšumování (on-line denoising):** odhadujeme $\theta = s[n]$ v modelu $x[m] = s[m] + w[m]$, $m = 1, \dots, n$ (pro odhad používáme pouze data přítomná a minulé (např. pro odhad $s[2]$ mohu využít jen $x[1], x[2]$). Hledáme kauzální filtr.
2. **Vyhlazování (off-line smoothing):** $\theta = s[n]$ má být odhadnuto pro $n = 1, \dots, N$ za použití celé sady měření $\mathbf{x} = [x[1], x[2], \dots, x[N]]$ (např. pro odhad $s[2]$ máme k dispozici celé \mathbf{x}).
3. **Predikce:** odhadujeme $\theta = s[N+k]$, $k > 0$, za použití $\mathbf{x} = [x[1], x[2], \dots, x[N]]$.

Otázky na tělo: Kde je ten „filtr“? Může se Wienerův filtr měnit v čase?

Cvičení 11

- ▶ Majitel e-shopu má data o denních prodejích za prvních 290 dní v roce. Přijde mu, že za posledních 16 dní jdou prodeje nahoru a chtěl by na základě této hypotézy odhadnout, kolik bude mít prodejů do konce roku.