

# přednáška 12

- ▶ Kalmanův filtr

# Model signálu

Opět lineární model

$$x[n] = s[n] + w[n]$$

Kde  $s[n]$  je signál, který chceme odhadovat a  $w[n]$  je WGN s rozptylem  $\sigma_n^2$ .

MVU odhad je  $\hat{s}[n] = x[n]$ , ale  $\text{var}(\hat{s}[n]) = \sigma^2$ .

Pokud nad  $x[n]$  uvažujeme jako nad realizací náhodného procesu, pak dává smysl uvažovat korelaci mezi vzorky, která může být zachycena např. pomocí Gaussova-Markovova procesu první řádu

$$s[n] = as[n-1] + u[n]$$

Kde  $n \geq 0$ ,  $u[n]$  je WGN s rozptylem  $\sigma_u^2$ , a  $s[-1] \sim N(\mu_s, \sigma_s^2)$ .

Poznámka: signál začíná v  $n = 0$ , tedy nemůže být slabě stacionární.

# Vlastnosti Gauss-MarkovOVA procesu

Model signálu:

$$s[n] = as[n-1] + u[n]$$

Kde  $n \geq 0$ ,  $u[n]$  je WGN s rozptylem  $\sigma_u^2$ , a  $s[-1] \sim N(\mu_s, \sigma_s^2)$ .

Platí:

$$s[n] = a^{n+1}s[-1] + \sum_{k=0}^n a^k u[n-k]$$

A

$$E[s[n]] = a^{n+1}\mu_s$$

$$\text{var}[s[n]] = a^{2n+2}\sigma_s^2 + \sigma_u^2 \sum_{k=0}^n a^{2k}$$

Pro  $n \rightarrow \infty$  pak dostaneme

$$E[s[n]] \rightarrow 0$$

$$\text{var}[s[n]] \rightarrow \frac{\sigma_u^2}{1-a^2}$$

# Kalmanův filtr: definice problému

Model signálu:

$$s[n] = as[n - 1] + u[n]$$

Model dat:

$$x[n] = s[n] + w[n]$$

Kritérium optimality: BMSE

$$E[(s[n] - \hat{s}[n|n])^2]$$

- MMSE

$$\hat{s}[n|n] = E[s[n]|x[0], \dots, x[n]]$$

- Lineární odhad

$$\hat{s}[n|n] = \mathbf{C}_{\theta x} \mathbf{C}_{xx}^{-1} \mathbf{x}$$

# Kalmanův filtr: použití

Predikce:

$$\hat{s}[n|n-1] = a\hat{s}[n-1|n-1]$$

Minimum prediction MSE:

$$M[n|n-1] = a^2 M[n-1|n-1] + \sigma_u^2$$

Kalman Gain:

$$K[n] = \frac{M[n|n-1]}{\sigma_n^2 + M[n|n-1]}$$

Correction:

$$\hat{s}[n|n] = \hat{s}[n|n-1] + K[n](x[n] - \hat{s}[n|n-1])$$

Minimum MSE:

$$M[n|n] = (1 - K[n])M[n|n-1]$$

# Kalmanův filtr: vlastnosti

- Rozšíření MMSE na odhady časově proměnných parametrů
- Není potřeba inverze matic
- Vlastní „metrika kvality“, může být spočítána offline (i dříve než máme data)  $\rightarrow M[n|n]$  nezávisí na datech
- Data nemusí být slabě stacionární, ale pro  $n \rightarrow \infty$  bude platit  $\sigma_n^2 = \sigma^2$  (budou stacionární) a Kalmanův filtr a Wienerův filtr budou stejné

# cvičení 12

Mějme model signálu daný jako Gauss-Markov process

$$s[n] = as[n-1] + u[n]$$

kde  $a = 0,5$ ,  $s[-1] \sim N(0,1)$  a  $\sigma_u^2 = 2$ . Signál pozorujeme v šumu, tedy

$$x[n] = s[n] + w[n]$$

Kde  $w[n] \sim N(0, \sigma_n^2)$  pro  $\sigma_n^2 = (1/2)^n$ .

Spočtete predikci, její korekci a příslušné MSE pro  $n=0$ . Na simulaci ukažte, jak se vyvíjí MSE v čase (s rostoucím  $n$ ).

Provedte rekonstrukci signálu  $s$ .



# cvičení 12

- ▶ 1) *pokuswiener.m*: (syntetický příklad)  
Jak sestavit filtr pro vyhlazení původního signálu, abychom se zbavili šumu?  
Můžete využít také funkci *miso\_firwiener.m*
- ▶ 2) *noisyvoice.mat*: (data na příklad odečítání akustického echa)  
Pomocí LMS najděte filtr, který filtrováním signálu **noise** dává signál co nejvíce "podobný" signálu **x** a takový ho od signálu **x** odečtete.
- ▶ 3) *foetalECG.mat*: (data na příklad extrakce fetálního EKG)  
V souboru *foetalECG.mat* je záznam EKG těhotné ženy. Signály 2 až 6 jsou z abdominální oblasti, zatímco signály 7 až 9 jsou z oblasti hrudní. Pomocí LMS najděte filtr, kterým z vybraného EKG kanálu z abdominální oblasti odečtete vybraný signál z oblasti hrudní. Výsledkem by měl být záznam fetálního EKG bez zarušení, které způsobuje silný signál EKG matky.



# Modelování jednorozměrného signálu/DAT pomocí náhodných veličin

- ▶ Obecně: náhodný digitální signál je posloupnost náhodných veličin
- ▶ i.i.d. posloupnost
- ▶ Jakou roli hrají parametry v pdf
- ▶ Co je to odhad?
- ▶ Příklady z knihy: Jak modelovat
  - ▶ Nepřesné měření stejnosměrného napětí
  - ▶ Odraz radarového pulzu od letadla
  - ▶ Signál dopadající na lineární soustavu senzorů (sonar)

# materiály

- ▶ <https://people.fjfi.cvut.cz/hobzatom/mast/mast.pdf>